

硬件要求

在开头给各位师傅放上计算B和显存之间的关系公式

<https://www.canirun.ai/>

gpu需要关注的3个参数

显存

显卡带宽

互联

游戏显卡 RTX40系列 24G 可以勉强塞下7B模型 性价比很高

互联之后组成工作站... ..

正常训练大模型的显卡

A100 两个版本 40G/80G 100w以上 貌似现在没货? (22年对中国禁售)

A800(中国特供阉割版) 互联比较差 100~200B轻松跑 (已禁运)

H100 为transformer架构特制底层引擎 算力2~3倍 A100 (已禁运)

H20 (中国特供阉割版) 算力不如A100 但保留了H100的带宽和互联

华为昇腾 算力基本与A100持平 CUDA软件生态差点意思

上下文推理模型(5000)

最低配置?

cpu

i7 8700k

E5-2666 B3

显卡

Tesla V100 16G

3060 12G

硬盘

512G SSD

内存

32G DDR4

行业垂直模型 4w

显卡

L40S 跑个16B差不多

<https://www.nvidia.cn/ai-on-rtx/>